

Privacy Router

AI 에이전트를 위한 주권 우선 프라이버시 레이어

GenAI & Blockchain · Term Project · June 2026

DH. Kim & M. Saadati

HOW IT WORKS

Extractor → **Judge** → **Router**

한국어/영어 프롬프트에서 민감 정보를 탐지하고, 마스킹 또는 로컬 처리를 결정한 뒤 적절한 모델로 라우팅합니다.

Local (Gemma 4)

Cloud (Gemini)

Mask & Send

Privacy Router

Problem

AI 에이전트가 민감 데이터를 외부 LLM으로 전송합니다

문제

AI 에이전트는 민감 데이터를 외부 **LLM**으로 전송합니다

기존 솔루션(OpenAI Privacy Filter)은 **영어/미국 PII(SSN, ZIP)** 중심. 한국 RRN, +82 전화번호, 연구 맥락을 이해하지 못합니다. **모두 공개** 또는 **모두 차단**만 가능합니다.

예시

주민등록번호 유출

주민등록번호(13자리) 같은 PII는 기존 LLM 가드레일이 놓칩니다. 정규표현식은 **맥락을 이해하지 못합니다**.

예시

미공개 연구 유출

연구 아이디어, 연구실 예산, 제출 계획 — **경쟁 정보**는 정규식으로 탐지 불가능합니다.

결론

Privacy Router: 맥락 인식 프롬프트 방화벽

탐지, 마스킹, 라우팅 — 민감 데이터는 로컬에 안전하게, 안전한 쿼리만 클라우드로. **모든 사용자를 위한 데이터 주권**.

Target Users

AI 프롬프트에 민감 정보가 빈번하게 포함되지만, 기존 보안 솔루션은 영어 PII 위주로만 탐지합니다.



대학 연구자

미공개 논문 아이디어, 실험 설계, IRB 관련 데이터를 LLM에 입력합니다. **연구 경쟁력 보호**가 핵심입니다.



전문직 & 기업 연구원

사업 기밀, 내부 결정, 예산 데이터를 포함한 프롬프트를 생성합니다. **기업 비밀 보호** 필수입니다.



개인 사용자

주민번호, 전화번호, 이메일 등 **개인 식별 정보**가 무심코 프롬프트에 포함됩니다.

핵심 통찰

기존 솔루션(OpenAI Privacy Filter)은 **영어·미국 PII(SSN, ZIP)** 중심. 주민등록번호, +82 전화번호, 연구 기밀 같은 다국어 PII를 다루는 시스템은 존재하지 않습니다.

Architecture

사용자 프롬프트가 Privacy Router 파이프라인을 통과하는 과정



Extractor

Socratic 방법 기반 탐지 — SCREAMING_CASE 카테고리, 한국 특화 규칙으로 맥락적 민감도 판단

PII

식별 가능 정보

주민등록번호, 전화번호, 이메일, 여권번호, 이름+소속 쌍

"901212-1234567" → RESIDENT_REGISTRATION_NUMBER

"010-1234-5678" → CONTACT_NUMBER

연구

연구 비밀

미공개 연구, 내부 결정, 전략, 제조 계획

"새로운 Attention 메커니즘 아이디어"

→ UNPUBLISHED_RESEARCH_DATA

사업

사업 비밀

자격증명, 내부 URL, 예산, 급여

"API 키 sk-proj-..." → API_CREDENTIAL

"예산 5억원" → BUDGET_INFORMATION

태그는 SCREAMING_CASE 자유 형식 — SLM이 소크라테스 추론으로 맥락적으로 생성합니다. 하드코딩된 목록이 아닌 언어 독립적 탐지 규칙을 사용합니다.

Judge

단일축 마스킹 테스트 — ”민감한 구간을 [REDACTED]로 대체해도 사용자 요청이 의미 있는가?”

단일축 마스킹 테스트

"민감한 구간을 [REDACTED]로 대체해도 사용자 요청이 의미 있는가?"

동사 휴리스틱으로 결정: 생성(Creation) → mask_and_send, 조회(Consultation) → mask_and_send, 질의(Interrogation) → process_locally



예 → 마스킹 후 클라우드



아니오 → 로컬 API 사용

// 핵심: 단일축 마스킹 테스트

SENSITIVE_SPANS를 [REDACTED]로 대체 → 요청이 유지? → mask_and_send

SENSITIVE_SPANS를 [REDACTED]로 대체 → 요청이 손상? → process_locally

Router

순수 실행 레이어 (LLM 없음) — 결정 테이블, UID 기반 마스킹, 하이드레이션

ROUTE 1

External API

민감 스패를 플레이스홀더로 대체 → 클라우드 LLM 전송 → 응답에서 원본 복원

`mask_text()` → Cloud LLM → `hydrate_text()`

ROUTE 2

Local API

프롬프트 자체가 민감 정보에 관한 것일 때. **전체 처리가 로컬에서.**

`process_locally()` → DGX Spark GB10

ROUTE 3

사용자에게 질의

시스템이 결정을 내릴 수 없을 때. **사용자에게 확인 질의.**

`409` → `needs_input` → 사용자 선택

마스킹 컨트랙트

결정론적 마스킹: **UID 기반 플레이스홀더** (RESIDENT_REGISTRATION_NUMBER#1) 사용. 원본은 SQLite에 암호화 저장. 마스킹 → LLM → 복원 과정에서 원본이 클라우드에 절대 노출되지 않습니다.

Detection Examples

실제 탐지 결과 — 맥락적 이해가 핵심 강점

연구 아이디어 탐지

입력: "대조 학습을 증가하는 새로운 손실 함수를 설계 중인데, 다중 모달 정렬에 적용할 수 있습니다."

NOVEL_LOSS_FUNCTION
UNPUBLISHED_RESEARCH_DATA

→ mask_and_send (맥락적 탐지 — 키워드 없이)

사업 전략 탐지

입력: "StartupX를 500억원에 인수하고, 그들의 독자적 토크 나이저를 차기 릴리스에 통합할 계획입니다."

ACQUISITION_PLAN
FINANCIAL_FIGURE
PRODUCT_INTEGRATION

→ mask_and_send

PII 탐지

입력: "주민등록번호 901212-1234567으로 조회해주세요."

RESIDENT_REGISTRATION_NUMBER
→ mask_and_send (패턴 기반)

핵심: 맥락적 탐지가 진정한 강점입니다 — SLM은 패턴이 아닌 *의미*를 이해합니다. 태그는 소크라테스 추론으로 생성되는 자유 형식 SCREAMING_CASE입니다. Confidence: 0.88~0.98

Two-Phase Extraction

Phase 1: Socratic 추출 — Phase 2: Critic 패스가 Phase 1이 놓친 것을 찾음

TWO-PHASE EXTRACTOR

- Phase 1: Socratic 추출이 SCREAMING_CASE 민감도 카테고리를 생성.
- Phase 2: Critic 패스가 결과를 검토하고 빈틈을 보완. 중복 제거 및 환각 필터링으로 병합.

V2 결과

1 → 4

\$0

+4

7/7 달성 모델

추가 비용

개선된 케이스

V1 — PATTERN MATCHING

키워드 의존

명시적 단서에 의존: "주민등록번호", "결정", "채택".

결과: Gemini 3.1 Flash Lite만 사업/연구 기밀 탐지. 모든 오픈소스 모델: 0%.

V2 — CONTEXTUAL REASONING

질문 기반 추론

Extractor가 모든 문장에 두 가지 맥락 추론 질문을 적용합니다:

"이 문장이 내일 신문에 실리면, 경쟁사가 이득을 볼까?"
"출판 전에 공개되면, 연구자가 피해를 볼까?"

이 질문들은 SLM이 **키워드에 의존하지 않고** 민감 정보를 탐지할 수 있게 합니다. 모델은 *의미*를 이해합니다 — "TSMC 3nm 공정 채택" 같은 문장에도 "비밀"이나 "기밀"이라는 명시적 키워드 없이 사업 기밀로 분류됩니다.

Cost Analysis

\$0.075/월 — 비용 효율적인 Two-Tier 라우팅

\$0.075

월 예상 비용

46

7일간 프롬프트 수

31

민감 프롬프트 탐지

9

로컬 처리

TWO-TIER ROUTING

비용-성능 균형

MODEL	\$/1M TOK	V2 SCORE
Gemma 4 26B-A4B	\$0.06	7/7
Gemini 3.1 Flash Lite	\$0.25	7/7
DeepSeek v4 Flash	\$0.10	7/7
Ministral 3B	\$0.10	7/7

최적 비용 성능

Gemma 4 26B-A4B

\$0.06/1M tok — Gemini Flash Lite(\$0.25)와 동등한 7/7 완전 탐지를 4배 저렴하게 달성.

비용 효율 순위

1. Gemma 4 26B-A4B → \$0.009/case

2. Ministral 3B → \$0.014/case

3. DeepSeek v4 → \$0.014/case

4. Gemini Flash Lite → \$0.036/case

Privacy & Security

데이터 흐름과 위협 모델

데이터 흐름

민감 데이터는 로컬에 머무름

- 원본 텍스트 → 로컬 SLM에서만 처리
- 마스킹된 텍스트만 클라우드 LLM으로 전송
- 원본은 SQLite에 암호화 저장
- 복원은 로컬에서만 수행

위협 모델

보장된 보안 속성

- ✓ 민감 데이터 제로 유출 — 마스킹 없이는 외부 전송 불가
- ✓ 결정론적 마스킹 — 동일 입력 → 동일 마스킹 (재현 가능)
- ✓ 감사 가능 — 모든 결정이 로그에 기록
- ⚠ SLM 환각 위험 — 탐지 모델이 놓칠 수 있음 → Critic 패스로 완화

핵심 보안 원칙

”마스킹된 데이터만 클라우드로” — Privacy Router는 민감 데이터가 외부 LLM에 도달하는 것을 구조적으로 방지합니다. 사용자 동의 없이는 어떤 민감 정보도 외부로 전송되지 않습니다.

7-Day Usage Log

실제 사용 데이터 — 46 프롬프트, 31 민감 탐지, 22 마스킹, 9 로컬

46

총 프롬프트

15

안전 (외부 전송)

22

마스킹 후 전송

9

로컬 처리

라우팅 분포



DAY 1 일반 대화 5 프롬프트	DAY 2 이메일 작성 (PII) 7 프롬프트	DAY 3 논문 리뷰 6 프롬프트	DAY 4-7 연구 태스크 28 프롬프트
--------------------------	---------------------------------	--------------------------	------------------------------

핵심 발견: 7일간 **제로 유출** — 민감 정보가 포함된 프롬프트가 마스킹 없이 외부 API로 전송된 사례가 없습니다.

Demo

Hermes Agent 통합 — MCP 도구로 Privacy Router 호출

MCP SERVER

process(text, action, model)

단일 통합 도구. **action** 파라미터로 동작 제어:

auto → 전체 파이프라인 (탐지 → 라우팅 → 생성)

classify → 탐지만 (LLM 호출 없음)

generate → 마스킹 + LLM 전달

allow → 탐지 건너뛰기, 직접 LLM

OPENAI COMPATIBLE

/v1/chat/completions

OpenAI SDK 드롭인 프록시. **모든 에이전트**가 base URL 변경만으로 Privacy Router를 사용 가능.

Hermes Agent

llm: "http://privacy-router:8787/v1"

Hermes

Butler agent · MCP direct

OpenCode

CLI agent · Custom provider

맥락적 프라이버시 탐지를 위한 모델 크기의 하한선이 존재합니다.

Gemma 4 26B가 그 문턱을 넘었습니다 —
\$0.06/1M tok으로.

SUMMARY

탐지 프레임워크	Socratic 민감도 탐지
프롬프트 엔지니어링	v1 → v2: 0% → 100%
최적 모델	Gemma 4 26B · \$0.06/1M
통합	MCP + OpenAI Proxy
테스트 커버리지	64 unit + 17 eval
로드맵	Data → Prompt → Model